

```

1 PHASE 9 – PHÂN TÍCH YẾU KÉM VÀ HƯỚNG CẢI THIỆN
2 =====
3
4
5 PHẦN 1 – KẾT QUẢ HIỆN TẠI CỦA PHASE 9
6 -----
7
8 Phase 9 hiện tại thử 4 cấu hình LightGBM bằng cách thay đổi num_leaves và
9 max_depth, sau đó thử thêm calendar rescue với day_of_week và is_weekend.
10
11 Kết quả:
12 - WAPE Phase 5 gốc      : 17.732%
13 - WAPE Phase 9 tốt nhất: 17.725%
14 - Mức cải thiện        : 0.007% – gần như không đáng kể
15
16 Kết luận: Phase 9 hiện tại về cơ bản không cải thiện được gì thực chất.
17
18
19 =====
20 PHẦN 2 – 4 ĐIỂM YẾU CỤ THỂ CỦA PHASE 9
21 =====
22
23
24 ĐIỂM YẾU 1 – Tuning sai chỗ: chỉ thay hình dạng cây, không đụng đến
25 gốc rễ gây lỗi
26 -----
27
28 Phase 9 chỉ điều chỉnh num_leaves (15, 31, 63) và max_depth (-1, 10, 12).
29 Đây là hai tham số kiểm soát hình dạng của từng cây quyết định, không ảnh
30 hưởng đến việc model học được bao nhiêu từ dữ liệu.
31
32 Vấn đề: model đang sai ở những nhóm ngày cụ thể (Sunday, low_revenue) –
33 đây là vấn đề của dữ liệu đầu vào và cách model bị phạt khi sai, không
34 phải vấn đề của hình dạng cây.
35
36 Hậu quả: dù thay đổi bao nhiêu cấu hình num_leaves/max_depth, WAPE vẫn
37 dao động quanh 17.7% vì gốc rễ gây lỗi chưa được xử lý.
38
39
40 ĐIỂM YẾU 2 – Số cây cứng 400, không biết model có đang overfit không
41 -----
42
43 Tất cả 4 cấu hình đều dùng n_estimators=400 cố định. Model LightGBM có
44 thể đạt điểm tối ưu ở iteration 250 rồi bắt đầu overfit – nhưng Phase 9
45 không có cơ chế nào để phát hiện điều này.

```

46
47 Hậu quả: nếu model overfit ở iteration 280 mà vẫn train đến 400, 120 cây
48 thừa đó làm model ghi nhớ nhiều từ train thay vì học pattern thật, dẫn
49 đến WAPE validation cao hơn mức cần thiết.
50
51 Cách phát hiện: dùng early stopping – tách 15% cuối tập train theo thời
52 gian làm eval set nội bộ, để LightGBM tự dừng khi không còn cải thiện.
53 Sau đó đọc best_iteration_ để biết số cây thực sự tối ưu.
54
55
56 ĐIỂM YẾU 3 – Calendar rescue dùng sai feature, không giải quyết đúng
57 vấn đề Sunday
58 -----
59
60 Phase 7 phát hiện Sunday có WAPE 20.36% – cao nhất trong tuần, cách ngày
61 thấp nhất (Monday 14.02%) tới 6 điểm phần trăm.
62
63 Phase 9 phản ứng bằng cách thêm is_weekend (gộp Thứ 7 và Chủ nhật vào
64 một). Đây là sai vì:
65
66 - Thứ 7 và Chủ nhật có hành vi doanh thu khác nhau, gộp lại làm nhiễu
67 tín hiệu thay vì làm rõ nó.
68 - is_weekend chỉ là 0/1, không truyền được thông tin về vị trí của ngày
69 trong vòng tuần cho model.
70 - Kết quả: WAPE của calendar rescue là 17.770%, kém hơn model không có
71 calendar (17.725%).
72
73 Vấn đề thực: model cần biết Chủ nhật khác với các ngày còn lại như thế
74 nào, không phải biết cuối tuần khác ngày thường.
75
76
77 ĐIỂM YẾU 4 – Không xử lý nhóm low_revenue dù đã biết WAPE 28.32%
78 -----
79
80 Phase 7 ghi nhận rõ nhóm low_revenue có WAPE 28.32% – gần gấp đôi
81 high_revenue (khoảng 15%). Phase 9 không có bất kỳ ô code nào nhắm vào
82 điểm yếu này.
83
84 Nguyên nhân likely: nhóm low_revenue thường là các ngày bất thường (nghỉ
85 lễ, sự kiện đột xuất). LightGBM mặc định cho phép mỗi lá cây chỉ cần 20
86 mẫu – quá ít, dẫn đến model học vệt những ngày bất thường thay vì học
87 pattern chung.
88
89 Hậu quả: model tự tin quá mức với các ngày ít dữ liệu, tạo ra prediction
90 lệch xa thực tế ở nhóm low_revenue.

91
92
93
94
95
96
97
98
99
100
101
102
103
104
105
106
107
108
109
110
111
112
113
114
115
116
117
118
119
120
121
122
123
124
125
126
127
128
129
130
131
132
133
134
135

```
=====
PHẦN 3 – 4 HƯỚNG CẢI THIẾN TƯƠNG ỨNG
=====

CẢI THIẾN 1 – Thêm regularization để giải quyết low_revenue WAPE cao
-----

Tương ứng với Điểm yếu 4.

Thay vì chỉ thay num_leaves, thêm vào model_candidates các cấu hình có:
- min_child_samples tăng lên 30-50 (thay vì mặc định 20): buộc mỗi lá
  cây phải có đủ mẫu mới được tạo, tránh model học vệt ngày bất thường.
- reg_alpha (L1) khoảng 0.1 và reg_lambda (L2) khoảng 1.0: phạt model
  khi dùng quá nhiều feature phức tạp, buộc model học pattern phổ quát.

Kỳ vọng: WAPE nhóm low_revenue giảm, WAPE tổng có thể cải thiện nhẹ.


CẢI THIẾN 2 – Thêm early stopping để tìm số cây thực sự tối ưu
-----

Tương ứng với Điểm yếu 2.

Quy trình:
1. Cắt 15% cuối tập train (theo thứ tự thời gian, không random) làm
  eval set nội bộ.
2. Train với callbacks early_stopping(50): dừng nếu sau 50 rounds liên
  tiếp eval set không cải thiện.
3. Đọc best_iteration_ sau khi train xong.
4. Dùng best_iteration_ làm n_estimators cho tất cả cấu hình còn lại.

Tại sao cắt theo thời gian: đây là time series, nếu random split sẽ để
lộ dữ liệu tương lai cho model thấy trong lúc train – gây leakage.

Kỳ vọng: loại bỏ overfit ở các iteration cuối, WAPE validation giảm
đáng kể nếu model hiện đang bị overfit.


CẢI THIẾN 3 – Thay calendar rescue bằng cyclic encoding đúng cách
-----

Tương ứng với Điểm yếu 3.
```

136
137 Thay vì is_weekend, tạo:
138
139 - is_sunday: flag riêng cho Chủ nhật, tách hẳn khỏi Thứ 7.
140 - is_monday: flag riêng cho Thứ 2 (ngày WAPE thấp nhất – có thể học
141 được pattern khác biệt rõ).
142 - dow_sin và dow_cos (cyclic encoding): chuyển ngày trong tuần (0-6)
143 thành 2 giá trị sin/cos. Ví dụ: Chủ nhật (6) và Thứ 2 (0) sẽ được
144 biểu diễn là gần nhau trên vòng tròn tuần – model hiểu được tính tuần
145 hoàn mà binary encoding không làm được.
146 - month_sin và month_cos: tương tự cho tháng trong năm, giúp model hiểu
147 tháng 12 và tháng 1 liền kề nhau.

148
149 Kỳ vọng: WAPE Sunday giảm từ 20.36% xuống gần với các ngày khác trong
150 tuần. Nếu WAPE tổng cũng giảm thì đây là feature set cho Phase 10.

151
152
153 CẢI THIỆN 4 – Thêm cặp learning rate nhỏ + nhiều cây hơn

154 -----

155
156 Tương ứng với Điểm yếu 1.

157
158 Cả 4 cấu hình hiện tại dùng learning_rate 0.05 hoặc 0.03. Trong GBDT,
159 learning rate nhỏ hơn kết hợp với nhiều cây hơn là công thức tiêu chuẩn
160 để tăng chất lượng hội tụ – mỗi cây đóng góp ít hơn nhưng model học
161 chính xác hơn theo từng bước nhỏ.

162
163 Thêm vào model_candidates:

164 - learning_rate=0.01 với n_estimators=1000
165 - learning_rate=0.03 với n_estimators=800
166

167 Kết hợp với early stopping (Cải thiện 2) để không train thừa cây.

168
169 Kỳ vọng: thường giảm được 0.5-1.5% WAPE so với learning rate lớn hơn,
170 đặc biệt hiệu quả khi kết hợp với early stopping.

171
172
173 =====

174 PHẦN 4 – THỨ TỰ THỰC HIỆN VÀ ĐIỂM DỪNG

175 =====

176
177 Bước 1: Làm Cải thiện 2 (early stopping) trước – chi phí thấp nhất,
178 có thể phát hiện ngay model có đang overfit không.

179
180 Bước 2: Làm Cải thiện 1 và 4 cùng lúc – thêm các cấu hình regularized

181 và lr nhỏ vào model_candidates, train với early stopping.

182

183 Bước 3: Xem kết quả. Nếu WAPE tổng đã giảm xuống dưới 17%, dừng ở đây

184 và chuyển sang Phase 10.

185

186 Bước 4: Nếu WAPE tổng vẫn chưa cải thiện đủ, mới làm Cải thiện 3

187 (cyclic calendar) và kiểm tra WAPE theo weekday để xác nhận

188 Sunday đã tốt lên chưa.

189

190 Nguyên tắc xuyên suốt: mọi quyết định chọn model đều dựa trên

191 validation WAPE, không dùng test. Test chỉ dùng đúng một lần ở Phase 10.

192

193

194 =====

195 PHẦN 5 – BẢNG TÓM TẮT

196 =====

198 Điểm yếu	Nguyên nhân gốc	Cải thiện
199 -----	-----	-----
200 Tuning không hiệu quả	Thay num_leaves/max_depth,	Thêm lr nhỏ + n_est
201 WAPE chỉ giảm 0.007%	không đúng chỗ gây lỗi	cao + regularization
202		
203 Model có thể overfit ở	n_estimators=400 cứng,	Dùng early stopping,
204 iteration < 400	không có cơ chế dừng sớm	đọc best_iteration_
205		
206 Sunday WAPE 20.36% chưa	is_weekend gộp Sat+Sun,	Tách is_sunday riêng
207 được giải quyết	không tách đặc thù Sunday	+ cyclic dow_sin/cos
208		
209 low_revenue WAPE 28.32%	min_child_samples mặc định	Tăng min_child_samples
210 chưa được xử lý	quá nhỏ, model học vệt	+ reg_alpha/lambda
211		